Conteggio di N-grams in Python

eleonora.ristori

April 2023

1 Introduzione

In questa relazione viene presentato il progetto in cui vengono implementate in Python due versioni di una funzione che ha come scopo quello di contare gli n-grams di un testo dato in input. Le versioni sono una sequenziale e una parallela attraverso la libreria Joblib. Verrà mostrato come variano le performance di queste due funzioni al variare dei parametri di input.

2 Versione sequenziale

Le due versioni della funzione appena descritta sono state implementate come metodi della classe NGramCounter che ha come attributi un intero che rappresenta la lunghezza degli n-grams che si vuole contare ed una mappa in cui si accumula il conteggio totale delle occorrenze degli n-grams.

```
class NGramCounter:
    def __init__(self, length):
        self.nGramLength = length
        self.map = {}
```

La versione sequenziale è quella implementata nel metodo countNGrams:

```
def countNGrams(self, words):
    self.map = {}
    for word in words:
        if len(word) > self.nGramLength:
            ngrams = self.extractNGramsFromWord(word)
            for ngram in ngrams:
                if ngram in self.map:
                    self.map[ngram] = self.map[ngram] + 1
                else:
                    self.map[ngram] = 1
```

Il metodo riceve come parametro una lista contenente tutte le parole del testo di cui si vuole contare gli n-grams. Questa lista viene scorsa completamente e, ad ogni passo dell'iterazione, in primo luogo vengono estratti dalla parola tutti gli n-grams che contiene attraverso il metodo extractNGramsFromWord().

```
def extractNGramsFromWord(self, word):
    ngrams = []
    for i in range(0, len(word) - self.nGramLength + 1):
        ngrams.append(word[i:self.nGramLength + i])
    return ngrams
```

Successivamente, per ogni ngram estratto dalla parola viene incrementato il valore del corrispondente elemento della mappa e, in caso l'n-gram non fosse ancora stato aggiunto alla mappa, viene inizializzato il relativo valore a 1.

3 Versione parallela

Questa versione suddivide la lista delle parole in slices di lunghezza window_size in modo da distribuire il problema di contare gli n-grams in sottoproblemi più semplici eseguibili dai processi in maniera parallela con il metodo threadCount-Ngrams().

Questo metodo ha lo scopo di computare il numero di n-gram della slice che gli è passata in input, generando una mappa specifica per ogni processo in cui si accumulano i risultati parziali.

Con la chiamata alla funzione Parallel viene eseguito threadCountNgrams()

```
def threadCountNgrams(self, words):
    map = {}
    for word in words:
        if len(word) > self.nGramLength:
            ngrams = self.extractNGramsFromWord(word)
            for ngram in ngrams:
                if ngram in map:
                    map[ngram] = map[ngram] + 1
                else:
                    map[ngram] = 1
    return map
```

in modo parallelo e le mappe in cui sono raccolti i risultati parziali vengono inserite in result. Successivamente vengono scorsi i risultati dei singoli job in maniera sequenziale per evitare di introdurre l'overhead dovuto alla presenza di una sezione critica. Ecco il metodo descritto:

```
def parallelCountNGrams(self, words, n_jobs, window_size):
    slices = [slice(start, start + window_size)
      for start in range(0, len(words) - window_size+1, window_size)]
    slices.append(slice(len(words) - len(words) % window_size, len(words)))
    result = Parallel(n_jobs=n_jobs)(delayed(nGramCounter.threadCountNgrams)(words[sl]) for sl in slices)
    self.map = {}
    for i in range(len(result)):
        for ngram in result[i]:
            if ngram in self.map:
                self.map[ngram] = self.map[ngram] + result[i][ngram]
            else:
                self.map[ngram] = result[i][ngram]
```

4 Confronto sulla performance delle due versioni

4.1 Valutazione delle performance al variare della dimensione della finestra e del numero di processi

Prima di confrontare i due metodi è stato testato il funzionamento della versione parallela dato che questa dipende da alcuni iperparametri, ovvero il numero dei thread e la window_size.
Per stabilire il numero di processi ottimale sul calcolatore utilizzato, il quale ha una CPU Intel® Core™ i7-9750H a 6 core, sono stati condotti diversi esperimenti utilizzando come input il libro David Copperfield di Charles Dickens replicato 50 volte per un totale di 17.892.500 parole.

4.1.1 Valutazione del numero ottimale di jobs

In questo primo esperimento, è stato variato il parametro n_jobs da 1 a 24 e sono stati memorizzati i tempi di esecuzione. Dal grafico riportato si osserva la variazione delle performance al crescere del numero dei processi, determinando quindi che il numero ottimale è proprio il numero di core del calcolatore ovvero 6, dato che una volta arrivati a 6 processi non si nota un miglioramento netto del tempo di esecuzione.

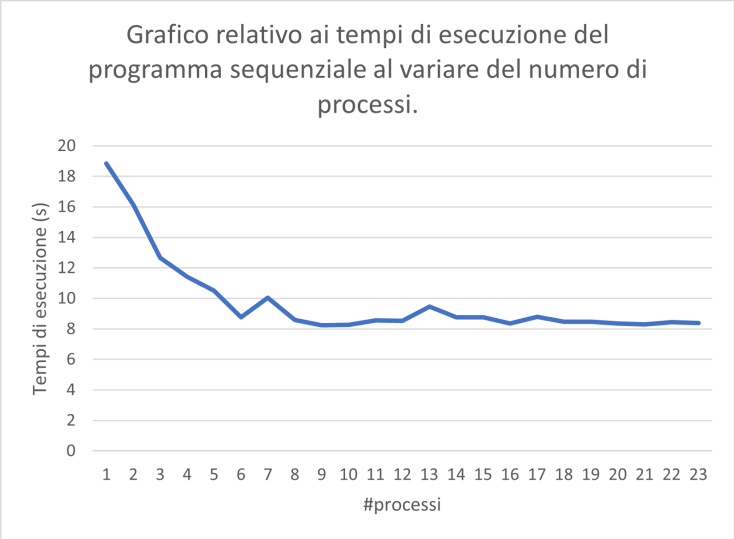

4.1.2 Valutazione della dimensione ottimale della finestra

Successivamente è stato ricercato il valore ottimale per la dimensione della finestra. Anche in questo caso sono stati memorizzati i tempi di esecuzione di diverse run successive con window_size variabile. Il valore ottimale è risultato significativamente diverso dalla dimensione totale della lista in input, fatto ragionevole dato che un'esecuzione con window_size pari a len(words) corrisponde alla versione sequenziale. Il valore ottimale della window_size inoltre si è visto anche essere significativamente diverso da 1 che porterebbe ad un grado di parallelizzazione massimo (ogni processo riceve una parola alla volta), ma che evidentemente introduce degli overhead eccessivi che portano ad un peggioramento delle performance. Si riporta il grafico dei vari tempi di esecuzione:

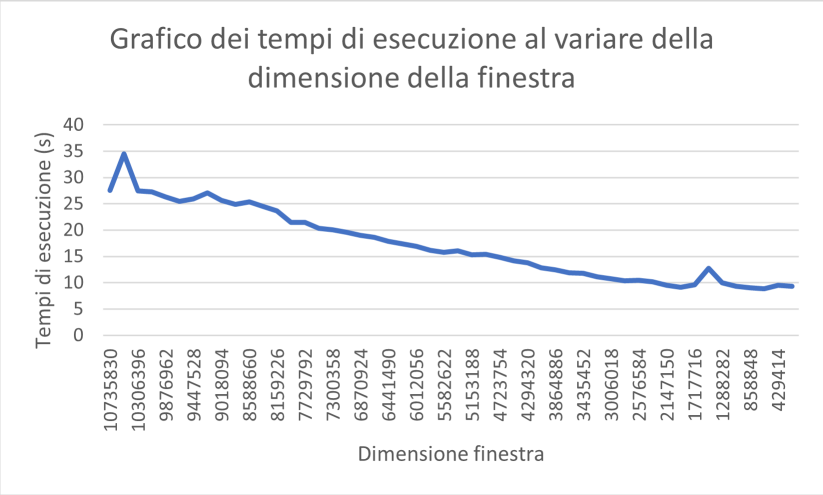

4.2 Confronto tra la versione sequenziale e parallela

Una volta compresi gli iperparametri ottimali per l'esecuzione della versione parallela, sono stati memorizzati i tempi di entrambe le versioni al variare della dimensione dell'input, cioè in particolare al variare del numero di volte per cui viene duplicato il libro David Copperfield. I risultati sono riportati nel grafico:

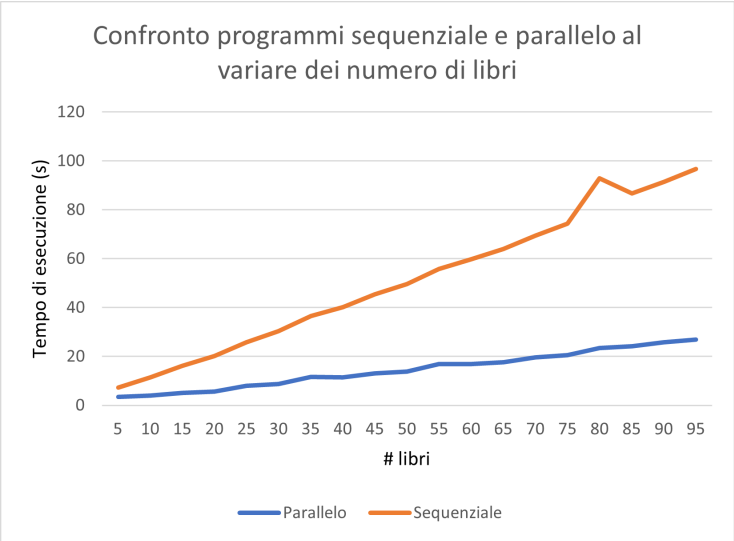

Nella figura sottostante si riportano i risultati relativi allo speedup che si assesta intorno al valore di 2.5 al variare della dimensione dell'input.